# Técnicas de Busca e Ordenação (TBO)

#### **Radix Sort**

Departamento de Informática (DI) Centro Tecnológico (CT) Universidade Federal do Espírito Santo (UFES)

(Material baseado nos slides dos Professores Eduardo Zambon e Giovanni Comarela)

# Introdução

- Até agora: abstrair os itens a serem ordenados com a definição de uma chave de ordenação e fazer comparação de chaves.
- Outro método: algoritmos de ordenação por radicais (radix sorting) trabalham diretamente com os "dígitos" das chaves, comparando-as em partes.
- Aula de hoje: apresentação das diferentes implementações de radix e dos algoritmos de ordenação radix sort.
- Objetivos: compreender as aplicações e o funcionamento do método de ordenação radix sort.

#### Referências

#### Chapter 10 – Radix Sorting

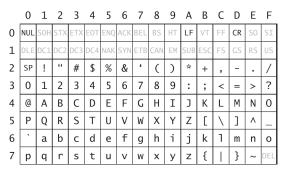
R. Sedgewick

# Strings e Alfabetos

#### Tipo de dado char

#### Tipo de dado char em C:

- Tipicamente é um inteiro de 8 bits.
- Suporta a codificação ASCII de 7 bits.
- Pode representar no máximo 256 caracteres.



Hexadecimal to ASCII conversion table

Em Java: suporta Unicode 16 de bits.

#### Strings em C

#### Tipo de dado string em C:

- Linguagem não possui um tipo string explícito.
- Representado por um char\*.
- Como arrays em C não carregam o seu próprio tamanho, strings são terminadas pelo caractere '\0'.
- Maior parte das operações implementadas em string.h.

Strings em C são mutáveis ⇒ Cuidado ao usar como chaves!

Manipulação de *strings* em C é muito propensa a erros. Exemplo:

```
int main() {
    char *s = "abc";
    s[0] = 'd'; // 'a' to 'd'
    // Segmentation fault... -_-
}
```

# Novo tipo de dado String

Novo tipo String para evitar o inferno astral de ter de lidar com array de char terminado por ' $\$ \0'.

```
typedef struct {
   char *c;
   int len;
} String;
```

#### Vantagens:

- Pode ajudar na imutabilidade tornando a estrutura opaca.
- Obter o tamanho de uma string agora é constante.
- Elimina erros como do slide anterior já que todas as strings são alocadas no heap.

# Novo tipo de dado String: operações

#### Comparar duas *strings* a partir do caractere na posição *d*.

```
int compare_from(String *s, String *t, int d) {
   int min = s->len < t->len ? s->len : t->len;
   for (int i = d; i < min; i++) {
      if (s->c[i] < t->c[i]) { return -1; }
      if (s->c[i] > t->c[i]) { return 1; }
   }
   return s->len - t->len;
}
```

#### Retorna:

- -1: se s < t.
- **1**: se s > t.
- 0: se s = t.

#### Atenção:

- Se s é prefixo de t, retorna < 0.
- Exemplo: she < shells.

# Novo tipo de dado String: operações

# Demais operações são triviais de implementar a partir de compare\_from.

```
int compare(String *s, String *t) {
   return compare_from(s, t, 0);
}
```

#### Interface usual de Item também fica simples.

#### Comparando duas strings

Q: Quantas comparações de caracteres são necessárias para comparar duas strings de comprimento *W*?

р	r	e	f	е	t	С	h
0	1	2	3	4	5	6	7
р	r	e	f	i	Х	е	S

Tempo de execução: Proporcional ao comprimento do maior prefixo em comum.

- Proporcional a *W* no pior caso.
- Mas geralmente é sublinear em relação a W.

#### **Alfabetos**

*String*: Sequência de símbolos (caracteres, dígitos) sobre um alfabeto fixo.

Radix: Número R de símbolos de um alfabeto (tamanho).

name	R()	lgR()	characters
BINARY	2	1	01
OCTAL	8	3	01234567
DECIMAL	10	4	0123456789
HEXADECIMAL	16	4	0123456789ABCDEF
DNA	4	2	ACTG
LOWERCASE	26	5	abcdefghijklmnopqrstuvwxyz
UPPERCASE	26	5	ABCDEFGHIJKLMNOPQRSTUVWXYZ
PROTEIN	20	5	ACDEFGHIKLMNPQRSTVWY
BASE64	64	6	ABCDEFGHIJKLMNOPQRSTUVWXYZabcdef ghijklmnopqrstuvwxyz0123456789+/
ASCII	128	7	ASCII characters
EXTENDED_ASCII	256	8	extended ASCII characters
UNICODE16	65536	16	Unicode characters

# Contagem Indexada por Chaves

# Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	1/2 N <sup>2</sup>	¼ N²	1	~
mergesort	N lg N	$N \lg N$	N	~
quicksort	1.39 N lg N *	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
	* probabilistic			

Limite inferior: pelo menos  $\sim N \lg N$  comparações.

- Q: É possível fazer melhor? (Apesar do limite inferior.)
- A: Sim, evitando comparação de chaves.
- Comparação de chaves: decisões binárias.
- Comparação por radix R: decisões têm R resultados.

# Key-indexed counting: suposições sobre as chaves

Suposição: chaves são inteiros entre  $0 \in R - 1$ .

Implicação: podemos usar as chaves como índices de *array*.

#### Aplicações:

- Ordenar uma string pela primeira letra.
- Ordenar empregados por seção.
- Ordenar números de telefone por código de área.
- Sub-rotina em um algoritmo de ordenação (em breve).

input name section		sorted result	
		(by section)	
Anderson	2	Harris	1
Brown	3	Martin	1
Davis	3	Moore	1
Garcia	4	Anderson	2
Harris	1	Martinez	2
Jackson	3	Miller	2
Johnson	4	Robinson	2
Jones	3	White	2
Martin	1	Brown	3
Martinez	2	Davis	3
Miller	2	Jackson	3
Moore	1	Jones	3
Robinson	2	Taylor	3
Smith	4	Williams	3
Taylor	3	Garcia	4
Thomas	4	Johnson	4
Thompson	4	Smith	4
White	2	Thomas	4
Williams	3	Thompson	4
Wilson	4	Wilson	4
	<b>†</b>		
	keys are		
sma	ıll integers		

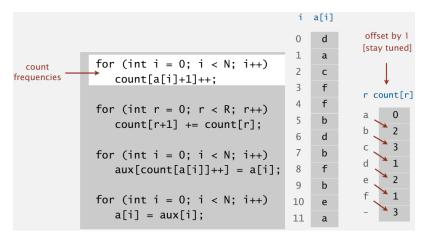
Objetivo: ordenar um array a [ ] de N inteiros entre 0 e R-1.

- Vetor auxiliar 1: count[] de tamanho R + 1.
- Vetor auxiliar 2: aux [] de tamanho N.
- No exemplo abaixo: R = 6.

```
a[i]
for (int i = 0; i < N; i++)
   count[a[i]+1]++;
for (int r = 0; r < R; r++)
   count[r+1] += count[r];
for (int i = 0; i < N; i++)
                                             f for 5
   aux[count[a[i]]++] = a[i]
for (int i = 0; i < N; i++)
                                   h
   a[i] = aux[i];
                              10
```

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.1: Contar a frequência de cada valor usando count [].



Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

P.2: Computar a frequência acumulada.

```
a[i]
              for (int i = 0; i < N; i++)
                                                           a
                 count[a[i]+1]++:
                                                                  r count[r]
              for (int r = 0; r < R; r++)
compute
                 count[r+1] += count[r];
cumulates
                                                           f
                                                           b
              for (int i = 0; i < N; i++)
                 aux[count[a[i]]++] = a[i];
                                                           b
                                                           f
              for (int i = 0; i < N; i++)
                                                       9
                                                           b
                                                                       12
                 a[i] = aux[i];
                                                      10
                                                           e
                                                      11
                                                           а
                                                       6 keys < d, 8 keys < e
                                                       so d's go in a[6] and a[7]
```

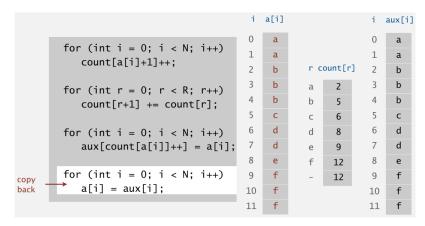
Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.3: Mover os itens para um vetor auxiliar.

```
a[i]
                                                                       aux[i]
                                                                         а
        for (int i = 0; i < N; i++)
                                                a
                                                                         а
            count[a[i]+1]++:
                                                       r count[r]
                                                С
                                                                         b
                                                                         b
        for (int r = 0; r < R; r++)
                                                                         b
            count[r+1] += count[r]:
                                                b
                                                                         C
                                                d
                                                                         d
        for (int i = 0; i < N; i++)
move
            aux[count[a[i]]++] = a[i];
                                                 b
                                                                         d
items
                                                 f
                                                            12
                                                                         e
        for (int i = 0; i < N; i++)
                                                 b
                                                            12
            a[i] = aux[i];
                                                                    10
                                            10
                                                 е
                                           11
                                                 a
                                                                    11
```

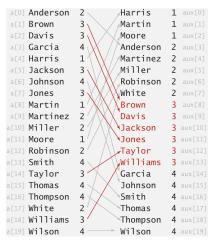
Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.4: Copiar de volta para o vetor original (se necessário).



# Key-indexed counting: análise

- Tempo de execução é ~ 3N + R.
- **E**spaço extra é  $\sim N + R$ .
- Método é estável.



#### Key-indexed counting: implementação em C

#### Versão final generalizada para uso em outros sorts:

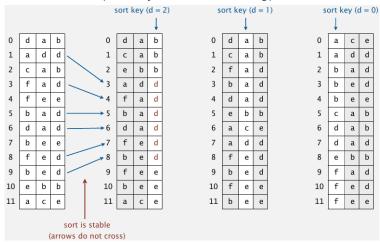
■ Faz a contagem sobre o d-ésimo caractere.

```
void count_sort(String* *a, String* *aux, int *count,
                int lo, int hi, int d, int R) {
    clear count array(count, R);
    for (int i = lo; i <= hi; i++) { // Count frequencies.</pre>
        count[char at(a[i], d) + 2]++;
    for (int r = 0; r < R+1; r++) { // Compute cumulates.
        count[r+1] += count[r];
    for (int i = lo; i <= hi; i++) { // Move items.
        int p = count[char at(a[i], d) + 1]++;
        aux[p] = a[i];
    for (int i = lo; i <= hi; i++) { // Copy back.
        a[i] = aux[i - lo];
```

#### LSD Radix Sort

# LSD (Least Significant Digit) radix sort

- Considera os caracteres da direita para a esquerda.
- Faz uma ordenação estável usando o d-ésimo caractere como chave (usa key-indexed counting).



# LSD radix sort: correção

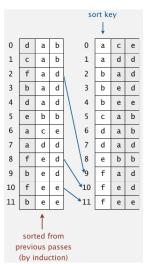
Proposição: LSD ordena *strings* de tamanho fixo de forma ascendente.

Prova (por indução em i):

Depois da passada *i*, as *strings* estão ordenadas pelos <u>últimos</u> *i* caracteres.

- Duas strings com chave de ordenação diferentes: key-indexed sort as coloca na ordem relativa adequada.
- Duas strings com chave de ordenação iguais: estabilidade as mantém ordem relativa adequada.

LSD sort é estável porque key-indexed sort é estável.



# LSD radix sort: implementação em C

```
void sort(String* *a, int N) {
    int W = 3; // Change accordingly to input size.
    int R = 256;
    String* *aux = create_str_array(N);
    int* count = create_count_array(R);
    for (int d = W-1; d >= 0; d--) {
        count sort(a, aux, count, 0, N-1, d, R);
    free (count):
    free (aux);
```

# Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N <sup>2</sup>	1/4 N <sup>2</sup>	1	V
mergesort	N lg N	N lg N	N	V
quicksort	1.39 N lg N*	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W(3N+R)	W (3N + R)	N + R	~
† fixed-length W keys	* probabilistic			

Q: E se as strings não são todas do mesmo tamanho?

#### Como fazer um censo nos anos de 1900?

#### Censo de 1880 (nos EUA):

- 1500 pessoas processando manualmente os dados.
- Processamento levou 7 anos.

Herman Hollerith: Desenvolveu uma máquina para automatizar a contagem e ordenação.

- Usou cartões perfurados para registrar os dados.
- Máguina ordena uma coluna por vez (em 12 pilhas).





Hollerith tabulating machine and sorter

punch card (12 holes per column)

Censo de 1890: Completado em 1 ano.

#### Como ficar rico ordenando nos anos de 1900?

#### Cartões perfurados (1900 a 1950):

- Também eram úteis para contabilidade, inventário e outros processos de negócios.
- Principal mídia para entrada, armazenamento e processamento de dados.

A empresa de Hollerith depois se fundiu com mais 3 outras para formar a Computing Tabulating Recording Corporation (CTRC). Empresa foi renomeada em 1924.



# LSD radix sort: um momento na história (1960s)







punched cards



card reader



mainframe



line printer

#### To sort a card deck

- start on right column
- put cards into hopper
- machine distributes into bins
- pick up cards (stable)
- move left one column
- continue until sorted



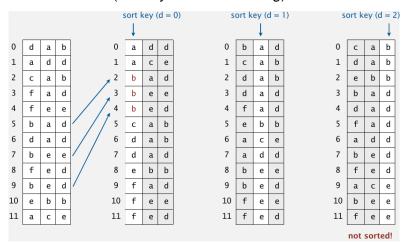


Lysergic Acid Diethylamide (Lucy in the Sky with Diamonds)

#### MSD Radix Sort

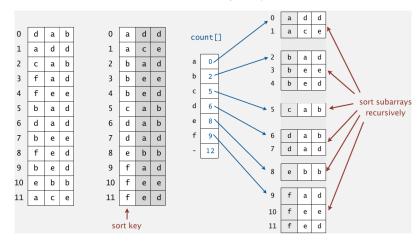
#### LSD invertido

- Considera os caracteres da esquerda para a direita.
- Faz uma ordenação estável usando o *d*-ésimo caractere como chave (usa *key-indexed counting*).



# MSD (Most Significant Digit) radix sort

- Particiona o array em R partes segundo o primeiro caractere, usando key-indexed counting.
- Ordena recursivamente cada partição.

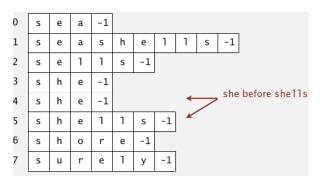


#### MSD radix sort: exemplo



# Strings de tamanho variável

Considerar que as *strings* têm um caractere extra no final menor que todos os outros.



Implementação em C é bem simples.

```
#define char_at(S, D) ((D < S->len) ? S->c[D] : -1)
```

#### MSD radix sort: implementação em C

Caractere "-1" fica na posição 1 de count.

```
for (int i = lo; i <= hi; i++) // Count frequencies.
    count[char_at(a[i], d) + 2]++;</pre>
```

Código abaixo reutiliza aux mas não count. Necessário porque chamadas recursivas modificariam o vetor count.

```
#define R 256
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
  if (hi <= lo) return:</pre>
  int* count = create count array(R);
  count_sort(a, aux, count, lo, hi, d, R); // Key-indexed count.
  for (int r = 1; r < R+1; r++) // Sort R arrays recursively.</pre>
    rec MSD(a, aux, lo + count[r], lo + count[r+1] - 1, d+1);
  free (count):
void sort(String* *a, int N) {
  String* *aux = create_str_array(N);
 rec MSD(a, aux, 0, N-1, 0);
  free (aux):
```

#### MSD radix sort: problemas de desempenho

Observação 1: algoritmo muito lento para sub-arrays pequenos.

- Cada chamada de função precisa do seu próprio array count.
- Tabela ASCII: *array* tem tamanho 256.
- Unicode: array tem tamanho 65,536!
- Mesmo para ordenar um sub-array de tamanho 2 é necessário alocar o array count todo: não sabemos o conteúdo a ser ordenado.

Observação 2: temos um grande número de *sub-arrays* pequenos por causa da recursão.

#### Cut-off para insertion sort

Solução: *cut-off* para *insertion sort* para *sub-arrays* pequenos.

*Insertion sort*, mas começando no *d*-ésimo caractere.

```
void insert_sort_from(Item *a, int lo, int hi, int d) {
   for (int i = lo; i <= hi; i++) {
      for (int j = i; j > lo && less_from(a[j], a[j-1], d); j--) {
         exch(a[j], a[j-1]);
      }
   }
}
```

Relembrando: função  $less\_from()$  compara as *strings* a partir do d-ésimo caractere.

Modificar a função recursiva como de costume.

```
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
   if (hi <= lo + CUTOFF - 1) {
      insert_sort_from(a, lo, hi, d);
      return;
   }</pre>
```

#### MSD radix sort: desempenho

- MSD examina o mínimo de caracteres necessários para ordenar as chaves.
- Número de caracteres examinados depende das chaves.
- Pode ser sub-linear (no melhor caso) em relação ao tamanho da entrada!

Random (sublinear)	Non-random with duplicates (nearly linear)	Worst case (linear)
<b>1E</b> I0402	are	1DNB377
<b>1H</b> YL490	by	1DNB377
1R0Z572	sea	1DNB377
2HXE734	seashells	1DNB377
<b>2I</b> YE230	seashells	1DNB377
2X0R846	sells	1DNB377
3CDB573	sells	1DNB377
3CVP720	she	1DNB377
<b>3I</b> GJ319	she	1DNB377
3KNA382	shells	1DNB377
3TAV879	shore	1DNB377
4CQP781	surely	1DNB377
<b>4Q</b> GI284	the	1DNB377
<b>4Y</b> HV229	the	1DNB377
Character	s examined by MSD	string sort

# Sumário: desempenho dos algoritmos de ordenação

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N <sup>2</sup>	1/4 N <sup>2</sup>	1	V
mergesort	$N \lg N$	$N \lg N$	N	V
quicksort	1.39 N lg N *	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W (3N + R)	W(3N+R)	N + R	V
MSD sort ‡	W(3N+R)	$N \log_R N$	N + D R	V
<ul><li>* probabilistic</li><li>† fixed-length W keys</li><li>‡ average-length W keys</li></ul>		D = function-call stack depth (length of longest prefix match)		

Técnicas de Busca e Ordenação (TBO)

#### MSD radix sort: análise empírica

#### Casos de teste:

- dict: dicionário com as palavras embaralhadas contendo 370,099 palavras distintas.
- book: versão em texto simples do livro Guerra e Paz, de Liev Tolstói. Contém 562,639 palavras (com repetições).

Algorithm	dict	book	
System qsort	0.409	0.559	
Standard quick sort	0.430	0.499	
Key-counting sort (Only w	orks with	strings	of len = $1$ )
LSD	0.967	0.601	
MSD1: standard	1.327	0.309	
MSD2: cut-off ins-sort	0.229	0.202	

Note como *cut-off* para *insertion sort* faz diferença no MSD!

# MSD radix sort vs. quick sort

#### Desvantagens do MSD radix sort:

- Espaço extra para aux[] e count[].
- Loop interno tem muitas instruções.
- Acessa a memória "aleatoriamente" (ruim para cache).

#### Desvantagens do quick sort.

- Número de comparações de strings não é linear.
- Precisa examinar várias vezes os mesmos caracteres quando há prefixos iguais longos.

#### Objetivo:

- Combinar as vantagens de MSD e quick sort.
- Vantagem do MSD: examina cada caractere uma vez.
- Vantagem do quicksort: loop interno simples, faz bom uso do cache.

# American flag sort

Otimização 0: cut-off para insertion sort.

Otimização 1: Substituir recursão por uma pilha explícita.

- Empilha os sub-arrays a serem ordenados na pilha.
   (Igual quick sort não-recursivo.)
- Feito isso, basta um único array count [].

Otimização 3: Faça o particionamento R-way in place.

- Elimina o array aux[].
- Sacrifica estabilidade.



Engineering Radix Sort

Peter M. McIlroy and Keith Bostic
University of California at Berkeley.

University of California at Berkeley; and M. Douglas McIlroy AT&T Bell Laboratories

ARITHACT. Radix sorting methods have excellent supprofice performance on string data, for which comparison is not a unit-time operation. Attractive for use in inge byte-addressible memories, these methods in the properties of the programmed algorithms. There ways to not string by strength and in-place "American flag" sort—are tilescribed with practical C programs. For hearth-puthy sort-traced with practical C programs. For hearth-puthy sort-taked with practical C programs. For hearth-puthy sort-taked with practical C programs. For hearth-puthy sort-taked with practical comparisons.